

AKADEMIA NAUK STOSOWANYCH
W NOWYM SĄCZU

Wydział Nauk Inżynieryjnych
Katedra Informatyki

DOKUMENTACJA PROJEKTOWA
ANALIZA OBRAZÓW Z ELEMENTAMI SZTUCZNEJ
INTELIGENCJI W DETEKCJI ZAGROŻEŃ

**Wykrywanie obrazów generowanych przez sztuczną
inteligencję**

Autor:
Agnieszka Ryś

Prowadzący:
mgr inż. Daniel Drozd

Nowy Sącz 2026

Spis treści

1. Cel projektu	4
1.1. Zakres projektu	4
1.2. Wymagania funkcjonalne	4
1.3. Wymagania niefunkcjonalne	5
2. Analiza problemu	6
2.1. Charakter problemu	6
2.2. Cel etapu bazowego	6
2.3. Najważniejsze trudności	7
3. Projektowanie	8
3.1. Architektura rozwiązania	8
3.2. Dane	8
3.3. Model bazowy	9
3.4. Etap twarzowy	9
3.5. Augmentacje i odporność	9
3.6. Środowisko uruchomieniowe	10
4. Implementacja	11
4.1. Trening modelu	11
4.2. Metryki	11
4.3. Wyniki etapu bazowego	12
4.4. Etap twarzowy	12
4.5. Test odporności	13
4.6. Benchmark OOD dla nowych generatorów	14
4.7. Tabela zbiorcza wyników	15
4.8. Analiza jakościowa błędów	15
4.9. Wyniki modelu twarzowego na nowych portretach	16
4.10. Interfejs demonstracyjny	17
5. Wnioski	18

Literatura	20
Spis rysunków	21
Spis tabel	22
Spis listingów	23

1. Cel projektu

Celem projektu jest stworzenie systemu wykrywania obrazów generowanych przez sztuczną inteligencję. System wykorzystuje metody uczenia maszynowego do analizy cech wizualnych i identyfikacji obrazów, które zostały wygenerowane przez modele generatywne. W kontekście współczesnych zagrożeń problem ten ma znaczenie praktyczne między innymi dla wykrywania dezinformacji, podszywania się pod inne osoby oraz obniżania wiarygodności obrazu jako nośnika informacji. W projekcie uwzględniono zarówno klasyczny etap **real vs fake**, jak i osobny etap twarzowy, przeznaczony do analizy portretów i potencjalnych deepfake'ów.

1.1. Zakres projektu

Zakres projektu obejmuje zaprojektowanie, implementację oraz weryfikację systemu, który klasyfikuje obrazy na prawdziwe i wygenerowane przez AI. Prace objęły przygotowanie danych, budowę modeli, analizę odporności oraz sprawdzenie zachowania modeli na danych spoza głównego rozkładu treningowego.

- przygotowanie zbiorów danych i ich podział na zbiory treningowy, walidacyjny i testowy,
- implementacja modelu globalnego opartego o klasyfikację całego obrazu,
- implementacja osobnego etapu twarzowego z wykrywaniem twarzy i klasyfikacją cropów,
- przygotowanie benchmarku OOD dla nowszych generatorów obrazów,
- analiza skuteczności, odporności oraz ograniczeń modeli,
- przygotowanie lokalnego interfejsu demonstracyjnego do ręcznych testów i analizy wyników.

1.2. Wymagania funkcjonalne

- wczytanie danych z ustalonej struktury katalogów **train/val/test**,
- konfiguracja parametrów treningu i modelu z pliku konfiguracyjnego,
- preprocessing obrazów oraz wdrożenie augmentacji uodparniających system na popularne degradacje jakości,

- trening modelu oraz zapis najlepszego checkpointu,
- ewaluacja modelu i raport metryk Accuracy, Precision, Recall, F1 i ROC-AUC,
- automatyczne wydzielanie rejonu twarzy i podanie go do dedykowanego modelu twarzowego,
- wizualizacja przesłanek decyzyjnych modelu przy użyciu map Grad-CAM [1].

1.3. Wymagania niefunkcjonalne

- przenośność — możliwość uruchomienia na środowisku Windows/Linux,
- wydajność — wsparcie dla akceleracji GPU i rozsądny czas trenowania,
- odtwarzalność — zapisywanie konfiguracji, checkpointów i podsumowań eksperymentów,
- niezawodność — czytelne zarządzanie wyjątkami, np. w przypadku braku wykrytej twarzy,
- interpretowalność — możliwość ręcznej analizy logiki decyzyjnej modelu,
- bezpieczeństwo — lokalne przetwarzanie danych bez konieczności wysyłania obrazów do usług zewnętrznych.

2. Analiza problemu

Rozwój modeli generatywnych spowodował, że obrazy syntetyczne stały się łatwe do wytworzenia i coraz trudniejsze do odróżnienia od zwykłych fotografii. Zjawisko to dotyczy zarówno klasycznych sieci GAN [2], jak i nowszych modeli dyfuzyjnych [3]. Problem ma znaczenie praktyczne w kilku obszarach: dezinformacji, podszywaniu się pod inne osoby, publikowaniu sfałszowanych materiałów wizualnych oraz obniżaniu wiarygodności obrazu jako nośnika informacji. W projekcie przyjęto, że pierwszym krokiem powinno być zbudowanie modelu bazowego wykrywającego obrazy typu *real* oraz *fake*.

2.1. Charakter problemu

Obrazy generowane przez AI mogą zawierać artefakty trudne do uchwycenia dla człowieka, ale rozpoznawalne przez model uczony na odpowiednio dobranym zbiorze danych. Do takich cech można zaliczyć:

- nienaturalną spójność lub niespójność tekstur,
- charakterystyczne błędy w drobnych detalach,
- zbyt gładkie przejścia tonalne,
- artefakty wynikające z procesu generacji lub późniejszej kompresji obrazu.

W praktyce problem nie sprowadza się jednak tylko do znalezienia jednego modelu o wysokiej skuteczności. Istotne jest również to, czy model pozostaje odporny na pogorszenie jakości obrazu, takie jak rozmycie, kompresja JPEG czy zmniejszenie rozdzielczości. Z punktu widzenia zastosowań praktycznych właśnie te przypadki są szczególnie ważne, ponieważ obrazy rozpowszechniane w mediach społecznościowych lub komunikatorach rzadko zachowują oryginalną jakość.

2.2. Cel etapu bazowego

W pierwszym etapie projektu założono budowę rozwiązania, które:

- przyjmuje cały obraz jako wejście,
- klasyfikuje go do jednej z dwóch klas: *real* lub *fake*,
- zapisuje pełne metryki i checkpointy,

- pozwala na wznowienie treningu,
- umożliwia interpretację decyzji modelu za pomocą Grad-CAM,
- może zostać później rozszerzone o osobny moduł analizy twarzy.

Takie podejście pozwala najpierw zbudować solidny punkt odniesienia, a dopiero później przejść do trudniejszego zagadnienia deepfake twarzy.

2.3. Najważniejsze trudności

W trakcie analizy problemu zidentyfikowano kilka kluczowych trudności:

- obrazy spoza rozkładu treningowego mogą być klasyfikowane z dużą pewnością, ale błędnie,
- portrety niskiej jakości i obrazy po kompresji mogą powodować fałszywe alarmy,
- ilustracje i anime nie należą do głównego zakresu modelu fotograficznego,
- skuteczność mierzona na zbiorze testowym nie zawsze przekłada się wprost na zachowanie modelu na obrazach z zewnątrz.

Z tego względu poza samym treningiem konieczne było dodanie testu odporności oraz prostego mechanizmu ostrzegania o niskiej jakości obrazu w interfejsie demonstracyjnym.

3. Projektowanie

3.1. Architektura rozwiązania

Projekt został podzielony na kilka logicznych modułów, z których każdy odpowiada za inny fragment eksperymentu:

- `dataset.py` — przygotowanie danych, transformacje i augmentacje,
- `split_dataset.py` — przygotowanie struktury `train/val/test`,
- `model.py` — tworzenie modelu na bazie biblioteki `timm`,
- `train.py` — trening, checkpointy, metryki i early stopping,
- `predict.py` oraz `inference.py` — inferencja dla pojedynczego obrazu,
- `robustness_eval.py` — test odporności na spadek jakości,
- `deepfake_faces.py` oraz `face_utils.py` — wykrywanie twarzy i przygotowanie cropów,
- `compare_face_models.py` — porównanie modelu globalnego i twarzowego,
- `error_analysis.py` — analiza błędów i eksport przykładów,
- `web_demo.py` — lokalny interfejs demonstracyjny.

Takie rozdzielenie upraszcza dalszy rozwój projektu, ponieważ etap globalny i etap twarzowy mogą być rozwijane niezależnie.

3.2. Dane

W eksperymentach wykorzystano zbiór danych zorganizowany w klasy `real` i `fake`, a następnie podzielony na części:

- zbiór treningowy: 40800 obrazów,
- zbiór walidacyjny: 7200 obrazów,
- zbiór testowy: 12000 obrazów.

Taki podział pozwala oddzielić proces uczenia od strojenia i od finalnej oceny modelu.

W dalszym etapie przygotowano również:

- curated zbiór portretów do treningu modelu twarzowego,
- mały benchmark OOD z nowymi generatorami GPT i Gemini / Nano2,
- małe zbiory adaptacyjne do prób dostrajania modeli.

3.3. Model bazowy

Jako model bazowy wybrano architekturę **ResNet18** [4] dostępną w bibliotece **timm**. Wybór ten wynikał z kilku powodów:

- model jest lekki obliczeniowo i nadaje się do szybkich eksperymentów,
- posiada sprawdzoną architekturę dla klasyfikacji obrazów,
- można go uruchamiać efektywnie na GPU z wykorzystaniem wag wstępnie wytrenowanych.

Model przyjmuje obrazy przeskalowane do rozmiaru 224×224 i zwraca prawdopodobieństwo dla dwóch klas: **fake** oraz **real**.

3.4. Etap twarzowy

Do analizy portretów zastosowano osobny pipeline. Najpierw z obrazu wejściowego wykrywana jest twarz przy użyciu klasyfikatora Haar Cascade [5], a następnieycinany jest crop w stylu **face** lub **portrait**. Tak przygotowany obraz trafia do osobnego klasyfikatora twarzowego opartego o **ConvNeXt Tiny** [6].

Takie rozdzielenie miało umożliwić:

- odciążenie modelu od pełnego kontekstu kadru,
- skupienie analizy na obszarze najbardziej istotnym dla deepfake'ów,
- porównanie zachowania modelu globalnego i wyspecjalizowanego modelu twarzowego.

3.5. Augmentacje i odporność

Ze względu na charakter problemu już na etapie projektowania uznano, że zwykły trening na czystych obrazach nie będzie wystarczający. Dlatego zastosowano augmentacje związane z pogorszeniem jakości:

- kompresję JPEG,
- rozmycie Gaussa,
- dodawanie szumu,
- operacje downscale-upscale.

Celem tych modyfikacji było uodpornienie modelu na część przypadków spotykanych w praktyce, zwłaszcza po przejściu obrazów przez komunikatory i serwisy internetowe.

3.6. Środowisko uruchomieniowe

Projekt jest rozwijany w Pythonie z wykorzystaniem między innymi bibliotek:

- PyTorch,
- torchvision,
- timm,
- Pillow,
- OpenCV,
- Gradio.

Trening został zoptymalizowany pod GPU poprzez:

- wykorzystanie AMP,
- automatyczny dobór `batch size`,
- `channels_last`,
- `cudnn_benchmark`,
- dostrojenie `DataLoadera`.

Te decyzje projektowe pozwoliły wyraźnie poprawić praktyczne wykorzystanie karty graficznej podczas treningu.

4. Implementacja

4.1. Trening modelu

Najważniejszym elementem implementacji jest skrypt `train.py`, który odpowiada za:

- wczytanie konfiguracji z pliku `config.yaml`,
- przygotowanie modelu,
- trening i walidację,
- zapis najlepszych wag,
- wznowienie treningu z checkpointu,
- zapis historii uczenia i podsumowania do pliku JSON.

W trakcie pracy dodano także mechanizmy praktyczne, które okazały się istotne dla dłuższych eksperymentów:

- `early stopping`,
- checkpointy `best_model.pt`, `last_checkpoint.pt` i `interrupted_checkpoint.pt`,
- obsługę treningu na GPU z wykorzystaniem AMP,
- automatyczny dobór rozmiaru batcha,
- lepsze ustawienia loadera pod Windows i CUDA.

4.2. Metryki

Podczas ewaluacji modelu raportowane są:

- Accuracy,
- Precision Macro,
- Recall Macro,
- F1 Macro,
- ROC-AUC.

Metryki te pozwalają ocenić model nie tylko pod względem skuteczności ogólnej, ale też pod kątem jakości rozróżniania klas.

4.3. Wyniki etapu bazowego

Wcześniejszy model bazowy osiągnął na zbiorze testowym:

- Accuracy: 0.9339,
- F1 Macro: 0.9339,
- ROC-AUC: 0.9831.

Następnie przeprowadzono drugi trening z mocniejszymi augmentacjami odpornościowymi. Wyniki tego wariantu były następujące:

- Accuracy: 0.9268,
- Precision Macro: 0.9273,
- Recall Macro: 0.9267,
- F1 Macro: 0.9267,
- ROC-AUC: 0.9804.

Wariant ten okazał się minimalnie słabszy na czystym zbiorze testowym, ale lepiej przygotowany do dalszych analiz odporności.

4.4. Etap twarzowy

W drugim etapie projektu przygotowano osobną ścieżkę analizy portretów i cropów twarzy. W praktyce oznacza to:

- automatyczne wykrycie twarzy klasyfikatorem Haar Cascade,
- zapis cropu w stylu `face` albo `portrait`,
- trening osobnego modelu twarzowego niezależnego od klasyfikatora globalnego,
- możliwość porównania modelu globalnego i modelu twarzowego na tym samym zbiorze portretów.

Wariant twarzowy został oparty o architekturę `ConvNeXt Tiny`. Dla curated miksu wieloźródłowego uzyskano bardzo dobre wyniki na danych zbliżonych do treningowych:

- Accuracy: 0.9763,
- Precision Macro: 0.9765,
- Recall Macro: 0.9763,
- F1 Macro: 0.9763,
- ROC-AUC: 0.9982.

Pokazało to, że dla klasycznych danych portretowych model twarzowy może być bardzo skuteczny, ale nie przesądza jeszcze o jego odporności na nowe generatory obrazów.

4.5. Test odporności

Dla aktualnego modelu przeprowadzono osobny test odporności na spadek jakości obrazu. Sprawdzone między innymi przypadki:

- lekkiej i silnej kompresji JPEG,
- lekkiego i silnego rozmycia,
- lekkiego i silnego downscale,
- profilu mieszanego `mixed_quality`.

Najważniejsze obserwacje były następujące:

- lekkie zaburzenia obniżały skuteczność tylko nieznacznie,
- najsilniejszy spadek pojawiał się dla `jpeg_extreme`,
- przypadki mieszane obniżały skuteczność wyraźnie bardziej niż pojedyncza lekka degradacja.

Pokazuje to, że model jest już w pewnym stopniu odporny na pogorszenie jakości, ale nadal pozostaje wrażliwy na obrazy bardzo mocno skompresowane.

4.6. Benchmark OOD dla nowych generatorów

Aby sprawdzić, czy modele generalizują poza główny rozkład treningowy, przygotowano mały benchmark OOD złożony z:

- 20 obrazów wygenerowanych przez GPT,
- 20 obrazów wygenerowanych przez Gemini / Nano2,
- 40 prawdziwych zdjęć portretowych dobranych tak, aby stylistycznie przypominały obrazy syntetyczne.

Benchmark ten nie był częścią głównego zbioru treningowego. Jego celem było możliwie uczciwe sprawdzenie, jak modele zachowują się na nowszych generatorach i bardziej współczesnych portretach. W praktyce był to więc mały test zewnętrzny, pozwalający sprawdzić nie tylko skuteczność klasyfikacji, ale także odporność na przesunięcie rozkładu danych.

Na tym benchmarku model globalny uzyskał:

- Accuracy: 0.7125,
- Precision Macro: 0.7934,
- Recall Macro: 0.7125,
- F1 Macro: 0.6912,
- ROC-AUC: 0.8413.

Macierz pomyłek pokazała istotną asymetrię:

- 39 z 40 obrazów **fake** zostało wykrytych poprawnie,
- tylko 18 z 40 obrazów **real** zostało rozpoznanych poprawnie,
- aż 22 prawdziwe zdjęcia zostały oznaczone jako **fake**.

Wniosek z tego etapu jest ważny: model globalny nie zawodził głównie na nowych obrazach syntetycznych, lecz na nowych realistycznych portretach, dla których generował zbyt wiele fałszywych alarmów.

4.7. Tabela zbiorcza wyników

Najważniejsze wyniki eksperymentów zestawiono w tabeli 4.1. Pozwala ona porównać modele nie tylko na danych zbliżonych do treningowych, ale również na małym benchmarku OOD oraz po krótkiej adaptacji modelu twarzowego.

Tab. 4.1. Zbiorcze wyniki najważniejszych eksperymentów

Wariant	Accuracy	F1 Macro	ROC-AUC
Model globalny – base-line test	0.9339	0.9339	0.9831
Model globalny – wariant robust	0.9268	0.9267	0.9804
Model twarzowy ConvNeXt Tiny – curated test	0.9763	0.9763	0.9982
Model globalny – benchmark OOD	0.7125	0.6912	0.8413
Model twarzowy przed adaptacją – OOD (wy- kryte twarze)	ok. 0.51	ok. 0.49	ok. 0.52
Model twarzowy po adaptacji – test we- wnętrzny	0.8548	0.8548	0.9469

4.8. Analiza jakościowa błędów

Same metryki nie pokazują jeszcze, *jakiego rodzaju* obrazy są problematyczne. Dlatego wykonano również analizę jakościową przypadków błędnych klasyfikacji.

Na rysunku 4.1 pokazano przykład fałszywego alarmu modelu globalnego na prawdziwym portrecie. Tego typu przypadki były częste w benchmarku OOD i sugerowały, że model nauczył się częściowo traktować estetyczne, czyste portrety jako obrazy podejrzone.



Rys. 4.1. Przykład false positive na benchmarku OOD: prawdziwy portret sklasyfikowany jako **fake**

Na rysunku 4.2 pokazano odwrotny przypadek, czyli obraz syntetyczny wygenerowany przez GPT, który został oznaczony jako **real**. Takie próbki były rzadsze niż false positive modelu globalnego, ale bardzo istotne z punktu widzenia wiarygodności systemu.



Rys. 4.2. Przykład false negative na benchmarku OOD: obraz syntetyczny sklasyfikowany jako **real**

Takie przykłady potwierdzają, że problem generalizacji nie dotyczy wyłącznie pojedynczych metryk, ale ma również wymiar jakościowy: modele potrafią mylić się na wizualnie przekonujących portretach nawet wtedy, gdy na danych wewnętrznych osiągają bardzo wysokie wyniki.

4.9. Wyniki modelu twarzowego na nowych portretach

Porównanie wcześniejszych checkpointów twarzowych z benchmarkiem OOD pokazało, że sam dobry wynik na danych wewnętrznych nie wystarcza do poprawnej generalizacji na nowsze obrazy. Przed adaptacją:

- wariant `faces_hard_adapt` uzyskał Accuracy około 0.48 na podzbiorze z wykrytą twarzą,

- wariant `faces_convnext_v2` uzyskał Accuracy około 0.51 na tym samym benchmarku.

Oznacza to, że pierwotna wersja modelu twarzowego nie generalizowała poprawnie na najnowsze fotorealistyczne obrazy GPT / Gemini.

W dalszym kroku wykonano mały fine-tuning modelu `faces_convnext_v2` na cropach twarzy przygotowanych z nowych obrazów. Na wewnętrznym teście adaptacyjnym uzyskano:

- Accuracy: 0.8548,
- Precision Macro: 0.8552,
- Recall Macro: 0.8548,
- F1 Macro: 0.8548,
- ROC-AUC: 0.9469.

Wynik ten należy jednak interpretować ostrożnie, ponieważ dotyczy niewielkiego zbioru adaptacyjnego, a ręczne testy w interfejsie nadal pokazywały trudne przypadki, w których nowe obrazy syntetyczne były klasyfikowane jako `real`. Oznacza to, że adaptacja poprawiła zachowanie modelu, ale nie rozwiązała jeszcze problemu w sposób pełny.

4.10. Interfejs demonstracyjny

W celu zwiększenia użyteczności projektu przygotowano lokalne demo webowe w `Gradio`. Aplikacja umożliwia:

- załadowanie pojedynczego obrazu,
- wyświetlenie predykcji `real/fake`,
- pokazanie pewności modelu,
- wygenerowanie mapy Grad-CAM,
- pokazanie ostrzeżenia przy niskiej jakości obrazu,
- porównanie predykcji modelu globalnego i modelu twarzowego dla portretów.

Interfejs ten ma charakter demonstracyjny i stanowi przydatne narzędzie do ręcznej analizy zachowania modelu.

5. Wnioski

Projekt należy uznać za udany na poziomie inżynierskim i badawczym. Udało się zbudować kompletny pipeline do klasyfikacji obrazów **real** oraz **fake**, przygotować wariant globalny i twarzowy, wdrożyć narzędzia interpretowalności oraz przeprowadzić eksperymenty zarówno na danych wewnętrznych, jak i na małym benchmarku OOD z nowymi generatorami.

Do najważniejszych osiągnięć należy zaliczyć:

- poprawne uruchomienie treningu na GPU,
- uzyskanie wysokich wyników na bazowym zbiorze testowym,
- zbudowanie osobnego etapu twarzowego opartego o cropy twarzy,
- wdrożenie interpretowalności poprzez Grad-CAM,
- przygotowanie testu odporności na pogorszenie jakości,
- stworzenie lokalnego interfejsu demonstracyjnego,
- przygotowanie benchmarku OOD dla nowszych generatorów i przeprowadzenie analizy błędów.

Jednocześnie analiza praktyczna pokazała, że nawet bardzo dobry wynik ilościowy na danych zbliżonych do treningowych nie oznacza pełnej gotowości modelu do pracy na dowolnych danych. Szczególnie problematyczne okazały się:

- nowe realistyczne portrety spoza głównego rozkładu treningowego,
- obrazy po silnej kompresji,
- najnowsze fotorealistyczne generatory obrazów,
- małe zbiory adaptacyjne, które nie pozwalają jeszcze na pełną stabilizację modelu.

Najważniejszy wniosek metodologiczny jest następujący: model globalny stanowi mocny baseline dla fotografii i znanych danych, natomiast generalizacja na najnowsze generatory GPT / Gemini pozostaje ograniczona. W benchmarku OOD problem nie polegał wyłącznie na niewykrywaniu obrazów syntetycznych, ale również na generowaniu zbyt wielu fałszywych alarmów dla nowych prawdziwych portretów.

Równie istotny jest wniosek dotyczący etapu twarzowego. Sam fakt zastosowania osobnego modelu twarzowego nie gwarantuje poprawy na nowych danych. Pierwotne checkpointy twarzowe nie generalizowały dobrze na nowe obrazy GPT / Gemini, a dopiero mała adaptacja na nowych cropach pozwoliła uzyskać poprawę na zbiorze wewnętrznym. Nadal jednak ręczne testy pokazały trudne przypadki, w których nawet adaptowany model twarzowy klasyfikował syntetyczny portret jako **real**.

Oznacza to, że końcowy efekt pracy należy interpretować jako:

- działający system badawczy z pełnym pipeline’em,
- mocny baseline dla starszych i znanych danych,
- narzędzie pozwalające badać ograniczenia detekcji na nowszych generatorach,
- punkt wyjścia do dalszych prac nad lepszą generalizacją modeli twarzowych.

W kolejnych pracach najbardziej uzasadnione byłyby:

1. rozbudowanie zbioru OOD o większą liczbę obrazów z najnowszych generatorów,
2. przygotowanie większego i bardziej zrównoważonego zbioru adaptacyjnego dla twarzy,
3. sprawdzenie silniejszych metod detekcji twarzy i alternatywnych strategii croppingowania,
4. dalsza analiza modeli hybrydowych, które łączą sygnał globalny i twarzowy.

Można zatem stwierdzić, że projekt osiągnął wyraźny i mierzalny progres: posiada sprawdzony etap bazowy, rozszerzenie twarzowe, benchmark OOD oraz udokumentowaną analizę ograniczeń. Z punktu widzenia pracy końcowej jest to wartościowy rezultat, ponieważ pokazuje nie tylko implementację, ale też realistyczną ocenę granic skuteczności obecnych metod detekcji.

Bibliografia

- [1] Ramprasaath R. Selvaraju i in. „Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization”. W: *Proceedings of the IEEE International Conference on Computer Vision*. 2017.
- [2] Ian Goodfellow i in. „Generative Adversarial Nets”. W: *Advances in Neural Information Processing Systems 27*. 2014.
- [3] Jonathan Ho, Ajay Jain i Pieter Abbeel. „Denoising Diffusion Probabilistic Models”. W: *Advances in Neural Information Processing Systems 33*. 2020.
- [4] Kaiming He i in. „Deep Residual Learning for Image Recognition”. W: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2016.
- [5] Paul Viola i Michael Jones. „Rapid Object Detection using a Boosted Cascade of Simple Features”. W: *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*. 2001.
- [6] Zhuang Liu i in. „A ConvNet for the 2020s”. W: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (2022).

Spis rysunków

- 4.1. Przykład false positive na benchmarku OOD: prawdziwy portret sklasyfikowany jako **fake** 16
- 4.2. Przykład false negative na benchmarku OOD: obraz syntetyczny sklasyfikowany jako **real** 16

Spis tabel

4.1. Zbiorcze wyniki najważniejszych eksperymentów	15
--	----

Spis listingów