

AKADEMIA NAUK STOSOWANYCH
W NOWYM SĄCZU

Wydział Nauk Inżynierskich
Katedra Informatyki

DOKUMENTACJA PROJEKTOWA
ANALIZA OBRAZÓW Z ELEMENTAMI SZTUCZNEJ
INTELIGENCJI W DETEKCJI ZAGROŻEŃ

**Wykrywanie obrazów generowanych przez sztuczną
inteligencję**

Autor:
Agnieszka Ryś

Prowadzący:
mgr inż. Daniel Drozd

Nowy Sącz 2026

Spis treści

1. Cel projektu	4
1.1. Zakres projektu	4
1.2. Wymagania funkcjonalne	4
1.3. Wymagania niefunkcjonalne	5
2. Analiza problemu	6
2.1. Charakter problemu	6
2.2. Cel etapu bazowego	6
2.3. Najważniejsze trudności	7
3. Projektowanie	8
3.1. Architektura rozwiązania	8
3.2. Schemat przepływu danych	8
3.3. Dane	9
3.4. Model bazowy	10
3.5. Etap twarzowy	10
3.6. Augmentacje i odporność	10
3.7. Środowisko uruchomieniowe	11
3.8. Konfiguracje eksperymentów	11
4. Implementacja	13
4.1. Trening modelu	13
4.2. Sposób uczenia modeli	13
4.3. Metryki	14
4.4. Zakres testów i porównań	15
4.5. Wyniki etapu bazowego	15
4.6. Etap twarzowy	16
4.7. Test odporności	17
4.8. Benchmark OOD dla nowych generatorów	18
4.9. Tabela zbiorcza wyników	19
4.10. Analiza jakościowa błędów	20

4.11. Wyniki modelu twarzowego na nowych portretach	21
4.12. Interfejs demonstracyjny	22
5. Wnioski	24
5.1. Co udało się osiągnąć	24
5.2. Co było problematyczne i dlaczego	26
Literatura	28
Spis rysunków	29
Spis tabel	30
Spis listingów	31

1. Cel projektu

Celem projektu jest stworzenie systemu wykrywania obrazów generowanych przez sztuczną inteligencję. System wykorzystuje metody uczenia maszynowego do analizy cech wizualnych i identyfikacji obrazów, które zostały wygenerowane przez modele generatywne. W kontekście współczesnych zagrożeń problem ten ma znaczenie praktyczne między innymi dla wykrywania dezinformacji, podszywania się pod inne osoby oraz obniżania wiarygodności obrazu jako nośnika informacji. W projekcie uwzględniono zarówno klasyczny etap **real vs fake**, jak i osobny etap twarzowy, przeznaczony do analizy portretów i potencjalnych deepfake'ów.

1.1. Zakres projektu

Zakres projektu obejmuje zaprojektowanie, implementację oraz weryfikację systemu, który klasyfikuje obrazy na prawdziwe i wygenerowane przez AI. Prace objęły przygotowanie danych, budowę modeli, analizę odporności oraz sprawdzenie zachowania modeli na danych spoza głównego rozkładu treningowego.

- przygotowanie zbiorów danych i ich podział na zbiory treningowy, walidacyjny i testowy,
- implementacja modelu globalnego opartego o klasyfikację całego obrazu,
- implementacja osobnego etapu twarzowego z wykrywaniem twarzy i klasyfikacją cropów,
- przygotowanie benchmarku OOD dla nowszych generatorów obrazów,
- analiza skuteczności, odporności oraz ograniczeń modeli,
- przygotowanie lokalnego interfejsu demonstracyjnego do ręcznych testów i analizy wyników.

1.2. Wymagania funkcjonalne

- wczytanie danych z ustalonej struktury katalogów **train/val/test**,
- konfiguracja parametrów treningu i modelu z pliku konfiguracyjnego,
- preprocessing obrazów oraz wdrożenie augmentacji uodparniających system na popularne degradacje jakości,

- trening modelu oraz zapis najlepszego checkpointu,
- ewaluacja modelu i raport metryk Accuracy, Precision, Recall, F1 i ROC-AUC,
- automatyczne wydzielanie rejonu twarzy i podanie go do dedykowanego modelu twarzowego,
- wizualizacja przesłanek decyzyjnych modelu przy użyciu map Grad-CAM [1].

1.3. Wymagania niefunkcjonalne

- przenośność — możliwość uruchomienia na środowisku Windows/Linux,
- wydajność — wsparcie dla akceleracji GPU i rozsądny czas trenowania,
- odtwarzalność — zapisywanie konfiguracji, checkpointów i podsumowań eksperymentów,
- niezawodność — czytelne zarządzanie wyjątkami, np. w przypadku braku wykrytej twarzy,
- interpretowalność — możliwość ręcznej analizy logiki decyzyjnej modelu,
- bezpieczeństwo — lokalne przetwarzanie danych bez konieczności wysyłania obrazów do usług zewnętrznych.

2. Analiza problemu

Rozwój modeli generatywnych spowodował, że obrazy syntetyczne stały się łatwe do wytworzenia i coraz trudniejsze do odróżnienia od zwykłych fotografii. Zjawisko to dotyczy zarówno klasycznych sieci GAN [2], jak i nowszych modeli dyfuzyjnych [3]. Problem ma znaczenie praktyczne w kilku obszarach: dezinformacji, podszywaniu się pod inne osoby, publikowaniu sfałszowanych materiałów wizualnych oraz obniżaniu wiarygodności obrazu jako nośnika informacji. W projekcie przyjęto, że pierwszym krokiem powinno być zbudowanie modelu bazowego wykrywającego obrazy typu *real* oraz *fake*.

2.1. Charakter problemu

Obrazy generowane przez AI mogą zawierać artefakty trudne do uchwycenia dla człowieka, ale rozpoznawalne przez model uczony na odpowiednio dobranym zbiorze danych. Do takich cech można zaliczyć:

- nienaturalną spójność lub niespójność tekstur,
- charakterystyczne błędy w drobnych detalach,
- zbyt gładkie przejścia tonalne,
- artefakty wynikające z procesu generacji lub późniejszej kompresji obrazu.

W praktyce problem nie sprowadza się jednak tylko do znalezienia jednego modelu o wysokiej skuteczności. Istotne jest również to, czy model pozostaje odporny na pogorszenie jakości obrazu, takie jak rozmycie, kompresja JPEG czy zmniejszenie rozdzielczości. Z punktu widzenia zastosowań praktycznych właśnie te przypadki są szczególnie ważne, ponieważ obrazy rozpowszechniane w mediach społecznościowych lub komunikatorach rzadko zachowują oryginalną jakość.

2.2. Cel etapu bazowego

W pierwszym etapie projektu założono budowę rozwiązania, które:

- przyjmuje cały obraz jako wejście,
- klasyfikuje go do jednej z dwóch klas: *real* lub *fake*,
- zapisuje pełne metryki i checkpointy,

- pozwala na wznowienie treningu,
- umożliwia interpretację decyzji modelu za pomocą Grad-CAM,
- może zostać później rozszerzone o osobny moduł analizy twarzy.

Takie podejście pozwala najpierw zbudować solidny punkt odniesienia, a dopiero później przejść do trudniejszego zagadnienia deepfake twarzy.

2.3. Najważniejsze trudności

W trakcie analizy problemu zidentyfikowano kilka kluczowych trudności:

- obrazy spoza rozkładu treningowego mogą być klasyfikowane z dużą pewnością, ale błędnie,
- portrety niskiej jakości i obrazy po kompresji mogą powodować fałszywe alarmy,
- ilustracje i anime nie należą do głównego zakresu modelu fotograficznego,
- skuteczność mierzona na zbiorze testowym nie zawsze przekłada się wprost na zachowanie modelu na obrazach z zewnątrz.

Z tego względu poza samym treningiem konieczne było dodanie testu odporności oraz prostego mechanizmu ostrzegania o niskiej jakości obrazu w interfejsie demonstracyjnym.

3. Projektowanie

3.1. Architektura rozwiązania

Projekt został podzielony na kilka logicznych modułów, z których każdy odpowiada za inny fragment eksperymentu:

- `dataset.py` — przygotowanie danych, transformacje i augmentacje,
- `split_dataset.py` — przygotowanie struktury `train/val/test`,
- `model.py` — tworzenie modelu na bazie biblioteki `timm`,
- `train.py` — trening, checkpointy, metryki i early stopping,
- `predict.py` oraz `inference.py` — inferencja dla pojedynczego obrazu,
- `robustness_eval.py` — test odporności na spadek jakości,
- `deepfake_faces.py` oraz `face_utils.py` — wykrywanie twarzy i przygotowanie cropów,
- `compare_face_models.py` — porównanie modelu globalnego i twarzowego,
- `error_analysis.py` — analiza błędów i eksport przykładów,
- `web_demo.py` — lokalny interfejs demonstracyjny.

Takie rozdzielenie upraszcza dalszy rozwój projektu, ponieważ etap globalny i etap twarzowy mogą być rozwijane niezależnie.

3.2. Schemat przepływu danych

Na potrzeby projektu przygotowano dwa uzupełniające się tory analizy: globalny, działający na całym obrazie, oraz twarzowy, uruchamiany dla portretów po wykryciu twarzy. Uproszczony przepływ danych przedstawiono w tabeli 3.1.

Tab. 3.1. Uproszczony schemat działania systemu

Etap	Opis działania
Obraz wejściowy	Użytkownik przekazuje pojedynczy obraz do skryptu inferencji albo interfejsu demonstracyjnego.
Preprocessing	Obraz jest wczytywany, przeskalowywany do rozmiaru 224 x 224 i normalizowany zgodnie z wymaganiami modelu.
Model globalny	Klasyfikator analizuje cały kadr i zwraca predykcję real/fake wraz z poziomem pewności.
Detekcja twarzy	Dla portretów wykonywane jest wykrycie twarzy oraz przygotowanie cropu w stylu face albo portrait .
Model twarzowy	Osobny klasyfikator ocenia wycięty obszar twarzy i pozwala porównać wynik z modelem globalnym.
Interpretacja	Dla wybranych próbek generowana jest mapa Grad-CAM, która pokazuje obszary istotne dla decyzji modelu.

3.3. Dane

W eksperymentach wykorzystano zbiór danych zorganizowany w klasy **real** i **fake**, a następnie podzielony na części:

- zbiór treningowy: 40800 obrazów,
- zbiór walidacyjny: 7200 obrazów,
- zbiór testowy: 12000 obrazów.

Taki podział pozwala oddzielić proces uczenia od strojenia i od finalnej oceny modelu.

W dalszym etapie przygotowano również:

- curated zbiór portretów do treningu modelu twarzowego,
- mały benchmark OOD z nowymi generatorami GPT i Gemini / Nano2,
- małe zbiory adaptacyjne do prób dostrajania modeli.

3.4. Model bazowy

Jako model bazowy wybrano architekturę **ResNet18** [4] dostępną w bibliotece **timm**. Wybór ten wynikał z kilku powodów:

- model jest lekki obliczeniowo i nadaje się do szybkich eksperymentów,
- posiada sprawdzoną architekturę dla klasyfikacji obrazów,
- można go uruchamiać efektywnie na GPU z wykorzystaniem wag wstępnie wytrenowanych.

Model przyjmuje obrazy przeskalowane do rozmiaru **224 x 224** i zwraca prawdopodobieństwo dla dwóch klas: **fake** oraz **real**.

3.5. Etap twarzowy

Do analizy portretów zastosowano osobny pipeline. Najpierw z obrazu wejściowego wykrywana jest twarz przy użyciu klasyfikatora Haar Cascade [5], a następnieycinany jest crop w stylu **face** lub **portrait**. Tak przygotowany obraz trafia do osobnego klasyfikatora twarzowego opartego o **ConvNeXt Tiny** [6].

Takie rozdzielenie miało umożliwić:

- odciążenie modelu od pełnego kontekstu kadru,
- skupienie analizy na obszarze najbardziej istotnym dla deepfake'ów,
- porównanie zachowania modelu globalnego i wyspecjalizowanego modelu twarzowego.

3.6. Augmentacje i odporność

Ze względu na charakter problemu już na etapie projektowania uznano, że zwykły trening na czystych obrazach nie będzie wystarczający. Dlatego zastosowano augmentacje związane z pogorszeniem jakości:

- kompresję JPEG,
- rozmycie Gaussa,
- dodawanie szumu,

- operacje downscale-upscale.

Celem tych modyfikacji było uodpornienie modelu na część przypadków spotykanych w praktyce, zwłaszcza po przejściu obrazów przez komunikatory i serwisy internetowe.

3.7. Środowisko uruchomieniowe

Projekt jest rozwijany w Pythonie z wykorzystaniem między innymi bibliotek:

- PyTorch,
- torchvision,
- timm,
- Pillow,
- OpenCV,
- Gradio.

Trening został zoptymalizowany pod GPU poprzez:

- wykorzystanie AMP,
- automatyczny dobór `batch size`,
- `channels_last`,
- `cudnn_benchmark`,
- dostrojenie `DataLoadera`.

Te decyzje projektowe pozwoliły wyraźnie poprawić praktyczne wykorzystanie karty graficznej podczas treningu.

3.8. Konfiguracje eksperymentów

W trakcie pracy uruchomiono kilka wariantów eksperymentalnych. Ich zestawienie znajduje się w tabeli 3.2. Tabela porządkuje, które modele były oceniane na danych wewnętrznych, a które służyły do sprawdzenia generalizacji na nowszych generatorach.

Tab. 3.2. Najważniejsze konfiguracje eksperymentów

Wariant	Model	Dane	Cel
Baseline globalny	ResNet18	Główny zbiór real/fake	Uzyskanie punktu odniesienia dla klasyfikacji całych obrazów.
Globalny robust	ResNet18	Główny zbiór z augmentacjami jakości	Sprawdzenie odporności na kompresję, rozmycie i skalowanie.
Model twarzowy	ConvNeXt Tiny	Curated portrety i cropy twarzy	Ocena, czy analiza twarzy poprawia klasyfikację portretów.
Benchmark OOD	Modele globalne i twarzowe	GPT, Gemini / Nano2 oraz dobrane zdjęcia prawdziwe	Sprawdzenie generalizacji poza głównym rozkładem treninowym.
Adaptacja twarzowa	ConvNeXt Tiny	Mały zbiór cropów z nowych obrazów	Wstępne dostrojenie modelu do nowych generatorów.

4. Implementacja

4.1. Trening modelu

Najważniejszym elementem implementacji jest skrypt `train.py`, który odpowiada za:

- wczytanie konfiguracji z pliku `config.yaml`,
- przygotowanie modelu,
- trening i walidację,
- zapis najlepszych wag,
- wznowienie treningu z checkpointu,
- zapis historii uczenia i podsumowania do pliku JSON.

W trakcie pracy dodano także mechanizmy praktyczne, które okazały się istotne dla dłuższych eksperymentów:

- `early stopping`,
- checkpointy `best_model.pt`, `last_checkpoint.pt` i `interrupted_checkpoint.pt`,
- obsługę treningu na GPU z wykorzystaniem AMP,
- automatyczny dobór rozmiaru batcha,
- lepsze ustawienia loadera pod Windows i CUDA.

4.2. Sposób uczenia modeli

Uczenie modeli miało charakter nadzorowany. Każdy obraz w zbiorze danych posiadał etykietę klasy `real` albo `fake`, a zadaniem sieci było nauczenie się rozróżniania tych dwóch kategorii na podstawie cech wizualnych obrazu. Dane zostały podzielone na zbiory `train`, `val` oraz `test`, dzięki czemu proces uczenia, strojenia i końcowej oceny był rozdzielony.

Podczas treningu wykorzystywano obrazy przeskalowane do rozmiaru 224×224 . Model bazowy uczył się na całych obrazach, natomiast model twarzowy na cropach

twarzy przygotowanych po detekcji twarzy. W obu przypadkach celem było zminimalizowanie błędu klasyfikacji binarnej oraz uzyskanie możliwie dobrych metryk na zbiorze walidacyjnym.

Proces uczenia obejmował:

- wykorzystanie wag wstępnie wytrenowanych, aby przyspieszyć uczenie i poprawić stabilność modelu,
- trening na zbiorze `train` oraz kontrolę jakości na zbiorze `val`,
- zapis najlepszego checkpointu na podstawie wyniku walidacyjnego,
- użycie `early stopping`, aby ograniczyć ryzyko przeuczenia,
- zastosowanie augmentacji jakościowych, takich jak kompresja JPEG, rozmycie, szum oraz operacje `downscale-upscale`,
- końcową ewaluację na zbiorze `test` oraz na dodatkowym benchmarku OOD.

W praktyce uczenie nie polegało więc wyłącznie na maksymalizacji wyniku na danych wewnętrznych. Ważnym elementem było sprawdzenie, czy model zachowuje się stabilnie także po pogorszeniu jakości obrazu oraz na nowych obrazach wygenerowanych przez inne narzędzia niż te obecne w głównym zbiorze danych.

4.3. Metryki

Podczas ewaluacji modelu raportowane są:

- Accuracy,
- Precision Macro,
- Recall Macro,
- F1 Macro,
- ROC-AUC.

Metryki te pozwalają ocenić model nie tylko pod względem skuteczności ogólnej, ale też pod kątem jakości rozróżniania klas.

4.4. Zakres testów i porównań

Weryfikacja projektu obejmowała kilka poziomów testów. Pierwszym z nich była klasyczna ewaluacja na zbiorze testowym, która pozwalała sprawdzić dokładność modelu na danych podobnych do treningowych. Drugim poziomem był test odporności, w którym ten sam zbiór testowy poddano degradacjom jakości. Trzecim poziomem był benchmark OOD, czyli sprawdzenie modeli na nowych generatorach i nowych portretach spoza głównego rozkładu treningowego.

Tab. 4.1. Zakres wykonanych testów i porównań

Rodzaj testu	Co sprawdzano	Najważniejszy wniosek
Test bazowy	Dokładność modelu globalnego na zbiorze testowym real/fake .	Model globalny uzyskał wysoką skuteczność na danych zbliżonych do treningowych.
Test robust	Wpływ kompresji, rozmycia i skalowania na wyniki.	Najbardziej problematyczna była bardzo silna kompresja JPEG.
Test modelu twarzowego	Skuteczność klasyfikatora działającego na cropach twarzy.	Model twarzowy osiągnął bardzo dobre wyniki na danych wewnętrznych.
Benchmark OOD	Zachowanie modeli na nowych generatorach GPT / Gemini oraz nowych prawdziwych portretach.	Wyniki spadły, a największym problemem były fałszywe alarmy dla prawdziwych portretów.
Porównanie globalny–twarzowy	Różnice między analizą całego obrazu i analizą twarzy.	Model twarzowy po adaptacji poprawił wyniki OOD, ale nie rozwiązał problemu całkowicie.

4.5. Wyniki etapu bazowego

Wcześniejszy model bazowy osiągnął na zbiorze testowym:

- Accuracy: 0.9339,
- F1 Macro: 0.9339,
- ROC-AUC: 0.9831.

Następnie przeprowadzono drugi trening z mocniejszymi augmentacjami odpornościowymi. Wyniki tego wariantu były następujące:

- Accuracy: 0.9268,
- Precision Macro: 0.9273,
- Recall Macro: 0.9267,
- F1 Macro: 0.9267,
- ROC-AUC: 0.9804.

Wariant ten okazał się minimalnie słabszy na czystym zbiorze testowym, ale lepiej przygotowany do dalszych analiz odporności.

4.6. Etap twarzowy

W drugim etapie projektu przygotowano osobną ścieżkę analizy portretów i cropów twarzy. W praktyce oznacza to:

- automatyczne wykrycie twarzy klasyfikatorem Haar Cascade,
- zapis cropu w stylu `face` albo `portrait`,
- trening osobnego modelu twarzowego niezależnego od klasyfikatora globalnego,
- możliwość porównania modelu globalnego i modelu twarzowego na tym samym zbiorze portretów.

Wariant twarzowy został oparty o architekturę `ConvNeXt Tiny`. Dla `curated` miksu wieloźródłowego uzyskano bardzo dobre wyniki na danych zbliżonych do treningowych:

- Accuracy: 0.9763,
- Precision Macro: 0.9765,
- Recall Macro: 0.9763,
- F1 Macro: 0.9763,
- ROC-AUC: 0.9982.

Pokazało to, że dla klasycznych danych portretowych model twarzowy może być bardzo skuteczny, ale nie przesądza jeszcze o jego odporności na nowe generatory obrazów.

4.7. Test odporności

Dla aktualnego modelu przeprowadzono osobny test odporności na spadek jakości obrazu. Sprawdzono między innymi przypadki:

- lekkiej i silnej kompresji JPEG,
- lekkiego i silnego rozmycia,
- lekkiego i silnego downscale,
- profilu mieszanego `mixed_quality`.

Najważniejsze obserwacje były następujące:

- lekkie zaburzenia obniżały skuteczność tylko nieznacznie,
- najsilniejszy spadek pojawiał się dla `jpeg_extreme`,
- przypadki mieszane obniżały skuteczność wyraźnie bardziej niż pojedyncza lekka degradacja.

Pokazuje to, że model jest już w pewnym stopniu odporny na pogorszenie jakości, ale nadal pozostaje wrażliwy na obrazy bardzo mocno skompresowane.

Tab. 4.2. Wpływ degradacji jakości obrazu na wyniki modelu globalnego

Profil testowy	Accuracy	F1 Macro	ROC-AUC
clean	0.9268	0.9267	0.9804
jpeg_low	0.9037	0.9036	0.9689
jpeg_extreme	0.8657	0.8651	0.9510
blur_light	0.9230	0.9230	0.9772
blur_strong	0.9022	0.9022	0.9646
downscale_light	0.9212	0.9212	0.9763
downscale_strong	0.9047	0.9047	0.9673
mixed_quality	0.8825	0.8825	0.9527

Tabela 4.2 pokazuje, że największy spadek skuteczności wystąpił dla profilu `jpeg_extreme`. W praktyce oznacza to, że bardzo silna kompresja może usuwać lub zniekształcać cechy, na których model opiera klasyfikację.

4.8. Benchmark OOD dla nowych generatorów

Aby sprawdzić, czy modele generalizują poza główny rozkład treningowy, przygotowano mały benchmark OOD złożony z:

- 20 obrazów wygenerowanych przez GPT,
- 20 obrazów wygenerowanych przez Gemini / Nano2,
- 40 prawdziwych zdjęć portretowych dobranych tak, aby stylistycznie przypominały obrazy syntetyczne.

Benchmark ten nie był częścią głównego zbioru treningowego. Jego celem było możliwie uczciwe sprawdzenie, jak modele zachowują się na nowszych generatorach i bardziej współczesnych portretach. W praktyce był to więc mały test zewnętrzny, pozwalający sprawdzić nie tylko skuteczność klasyfikacji, ale także odporność na przesunięcie rozkładu danych.

Na tym benchmarku model globalny uzyskał:

- Accuracy: 0.7125,
- Precision Macro: 0.7934,
- Recall Macro: 0.7125,
- F1 Macro: 0.6912,
- ROC-AUC: 0.8413.

Macierz pomyłek pokazała istotną asymetrię:

- 39 z 40 obrazów **fake** zostało wykrytych poprawnie,
- tylko 18 z 40 obrazów **real** zostało rozpoznanych poprawnie,
- aż 22 prawdziwe zdjęcia zostały oznaczone jako **fake**.

Wniosek z tego etapu jest ważny: model globalny nie zawodził głównie na nowych obrazach syntetycznych, lecz na nowych realistycznych portretach, dla których generował zbyt wiele fałszywych alarmów.

Tab. 4.3. Macierz pomyłek modelu globalnego na benchmarku OOD

	Predykcja fake	Predykcja real
Klasa fake	39	1
Klasa real	22	18

Macierz w tabeli 4.3 potwierdza, że model globalny był bardzo czuły na obrazy syntetyczne, ale równocześnie zbyt często oznaczał prawdziwe portrety jako **fake**. Z punktu widzenia użytkownika taki błąd jest istotny, ponieważ prowadzi do fałszywego oskarżenia prawdziwego zdjęcia o sztuczne pochodzenie.

Tab. 4.4. Porównanie modelu globalnego i twarzowego na podzbiorze OOD z wykrytą twarzą

Model	Accuracy	F1 Macro	ROC-AUC
Globalny na wykrytych twarzach	0.7143	0.6913	0.8360
Twarzowy po adaptacji	0.7922	0.7919	0.8738

Dla 77 obrazów, na których wykryto twarz, model twarzowy po adaptacji uzyskał lepsze metryki niż model globalny. Nie oznacza to jednak pełnego rozwiązania problemu, ponieważ oba modele zgadzały się tylko dla około 61% sparowanych próbek, a model twarzowy nadal popełniał błędy na części obrazów syntetycznych.

4.9. Tabela zbiorcza wyników

Najważniejsze wyniki eksperymentów zestawiono w tabeli 4.5. Pozwala ona porównać modele nie tylko na danych zbliżonych do treningowych, ale również na małym benchmarku OOD oraz po krótkiej adaptacji modelu twarzowego.

Tab. 4.5. Zbiorcze wyniki najważniejszych eksperymentów

Wariant	Accuracy	F1 Macro	ROC-AUC
Model globalny – base-line test	0.9339	0.9339	0.9831
Model globalny – wariant robust	0.9268	0.9267	0.9804
Model twarzowy ConvNeXt Tiny – curated test	0.9763	0.9763	0.9982
Model globalny – benchmark OOD	0.7125	0.6912	0.8413
Model twarzowy przed adaptacją – OOD (wykryte twarze)	ok. 0.51	ok. 0.49	ok. 0.52
Model twarzowy po adaptacji – test wewnętrzny	0.8548	0.8548	0.9469

4.10. Analiza jakościowa błędów

Same metryki nie pokazują jeszcze, *jakiego rodzaju* obrazy są problematyczne. Dlatego wykonano również analizę jakościową przypadków błędnych klasyfikacji.

Na rysunku 4.1 pokazano przykład fałszywego alarmu modelu globalnego na prawdziwym portrecie. Tego typu przypadki były częste w benchmarku OOD i sugerowały, że model nauczył się częściowo traktować estetyczne, czyste portrety jako obrazy podejrzone.



Rys. 4.1. Przykład false positive na benchmarku OOD: prawdziwy portret sklasyfikowany jako fake

Na rysunku 4.2 pokazano odwrotny przypadek, czyli obraz syntetyczny wygenerowany przez GPT, który został oznaczony jako **real**. Takie próbki były rzadsze niż false positive modelu globalnego, ale bardzo istotne z punktu widzenia wiarygodności systemu.



Rys. 4.2. Przykład false negative na benchmarku OOD: obraz syntetyczny sklasyfikowany jako **real**

Takie przykłady potwierdzają, że problem generalizacji nie dotyczy wyłącznie pojedynczych metryk, ale ma również wymiar jakościowy: modele potrafią mylić się na wizualnie przekonujących portretach nawet wtedy, gdy na danych wewnętrznych osiągają bardzo wysokie wyniki.

4.11. Wyniki modelu twarzowego na nowych portretach

Porównanie wcześniejszych checkpointów twarzowych z benchmarkiem OOD pokazało, że sam dobry wynik na danych wewnętrznych nie wystarcza do poprawnej generalizacji na nowe obrazy. Przed adaptacją:

- wariant **faces_hard_adapt** uzyskał Accuracy około 0.48 na podzbiorze z wykrytą twarzą,
- wariant **faces_convnext_v2** uzyskał Accuracy około 0.51 na tym samym benchmarku.

Oznacza to, że pierwotna wersja modelu twarzowego nie generalizowała poprawnie na najnowsze fotorealistyczne obrazy GPT / Gemini.

W dalszym kroku wykonano mały fine-tuning modelu **faces_convnext_v2** na cropach twarzy przygotowanych z nowych obrazów. Na wewnętrznym teście adaptacyjnym uzyskano:

- Accuracy: 0.8548,

- Precision Macro: 0.8552,
- Recall Macro: 0.8548,
- F1 Macro: 0.8548,
- ROC-AUC: 0.9469.

Wynik ten należy jednak interpretować ostrożnie, ponieważ dotyczy niewielkiego zbioru adaptacyjnego, a ręczne testy w interfejsie nadal pokazywały trudne przypadki, w których nowe obrazy syntetyczne były klasyfikowane jako **real**. Oznacza to, że adaptacja poprawiła zachowanie modelu, ale nie rozwiązała jeszcze problemu w sposób pełny.

4.12. Interfejs demonstracyjny

W celu zwiększenia użyteczności projektu przygotowano lokalne demo webowe w **Gradio**. Aplikacja umożliwia:

- załadowanie pojedynczego obrazu,
- wyświetlenie predykcji **real/fake**,
- pokazanie pewności modelu,
- wygenerowanie mapy Grad-CAM,
- pokazanie ostrzeżenia przy niskiej jakości obrazu,
- porównanie predykcji modelu globalnego i modelu twarzowego dla portretów.

Interfejs ten ma charakter demonstracyjny i stanowi przydatne narzędzie do ręcznej analizy zachowania modelu.



Rys. 4.3. Przykładowa wizualizacja Grad-CAM wygenerowana dla modelu globalnego

Wizualizacja Grad-CAM z rysunku 4.3 pełni funkcję diagnostyczną. Pozwala sprawdzić, czy model opiera decyzję na istotnych obszarach obrazu, czy raczej reaguje na przypadkowe tło, kompresję albo inne artefakty niezwiązane bezpośrednio z twarzą lub głównym obiektem.

5. Wnioski

Projekt należy uznać za udany na poziomie inżynierskim i badawczym. Udało się zbudować kompletny pipeline do klasyfikacji obrazów **real** oraz **fake**, przygotować wariant globalny i twarzowy, wdrożyć narzędzia interpretowalności oraz przeprowadzić eksperymenty zarówno na danych wewnętrznych, jak i na małym benchmarku OOD z nowymi generatorami.

Do najważniejszych osiągnięć należy zaliczyć:

- poprawne uruchomienie treningu na GPU,
- uzyskanie wysokich wyników na bazowym zbiorze testowym,
- zbudowanie osobnego etapu twarzowego opartego o cropy twarzy,
- wdrożenie interpretowalności poprzez Grad-CAM,
- przygotowanie testu odporności na pogorszenie jakości,
- stworzenie lokalnego interfejsu demonstracyjnego,
- przygotowanie benchmarku OOD dla nowszych generatorów i przeprowadzenie analizy błędów.

5.1. Co udało się osiągnąć

Najważniejszym rezultatem projektu jest działający system, który obejmuje cały proces: przygotowanie danych, trening modeli, ewaluację, analizę odporności, interpretowalność oraz lokalny interfejs demonstracyjny. Model globalny osiągnął wysoką dokładność na głównym zbiorze testowym, a model twarzowy uzyskał bardzo dobre wyniki na danych portretowych zbliżonych do treningowych.

Udało się również pokazać, że sama dokładność na klasycznym zbiorze testowym nie jest wystarczająca do pełnej oceny systemu. Dlatego w projekcie wykonano dodatkowe testy odporności oraz benchmark OOD. Dzięki temu dokumentacja pokazuje nie tylko najlepsze wyniki, ale też ograniczenia modelu w trudniejszych warunkach.

Tab. 5.1. Podsumowanie osiągniętych i nieosiągniętych celów

Obszar	Co udało się osiągnąć	Co pozostało ograniczeniem
Model globalny	Wysoka skuteczność na głównym zbiorze testowym: Accuracy 0.9339 dla baseline oraz 0.9268 dla wariantu robust.	Spadek skuteczności na benchmarku OOD do Accuracy 0.7125.
Odporność na jakość obrazu	Model zachował dobrą jakość dla lekkiego rozmycia i lekkiego downscale.	Silna kompresja JPEG oraz profil <code>mixed_quality</code> wyraźnie obniżały wyniki.
Model twarzowy	Bardzo dobry wynik na danych wewnętrznych: Accuracy 0.9763.	Słaba generalizacja pierwotnych checkpointów twarzowych na nowe generatory.
Adaptacja twarzowa	Poprawa po fine-tuningu na nowych cropach: Accuracy 0.8548 na teście adaptacyjnym.	Zbiór adaptacyjny był mały, więc wynik nie gwarantuje pełnej stabilności na dowolnych danych.
Interfejs demonstracyjny	Możliwość ręcznego testowania obrazów, porównania modeli i generowania Grad-CAM.	Interfejs ma charakter lokalnego demo, a nie gotowego systemu produkcyjnego.

Jednocześnie analiza praktyczna pokazała, że nawet bardzo dobry wynik ilościowy na danych zbliżonych do treningowych nie oznacza pełnej gotowości modelu do pracy na dowolnych danych. Szczególnie problematyczne okazały się:

- nowe realistyczne portrety spoza głównego rozkładu treningowego,
- obrazy po silnej kompresji,
- najnowsze fotorealistyczne generatory obrazów,
- małe zbiory adaptacyjne, które nie pozwalają jeszcze na pełną stabilizację modelu.

5.2. Co było problematyczne i dlaczego

Największym problemem okazała się generalizacja, czyli przeniesienie skuteczności z danych wewnętrznych na nowe obrazy spoza głównego zbioru treningowego. Przyczyną był przede wszystkim inny rozkład danych: nowe portrety i obrazy wygenerowane przez GPT / Gemini miały inną estetykę, inne artefakty oraz często wyższą jakość wizualną niż część danych treningowych.

Drugim problemem były fałszywe alarmy dla prawdziwych portretów. Model globalny bardzo dobrze wykrywał większość obrazów syntetycznych w benchmarku OOD, ale jednocześnie oznaczał wiele prawdziwych zdjęć jako **fake**. Możliwą przyczyną jest to, że model nauczył się traktować czyste, studyjne albo bardzo estetyczne portrety jako podejrzane, ponieważ podobne cechy często występują również w obrazach generowanych przez AI.

Trzecim problemem była wrażliwość na silne pogorszenie jakości obrazu. Kompresja JPEG, rozmycie i skalowanie mogą usuwać drobne artefakty, na których model opiera decyzję. W efekcie obraz po przetworzeniu przez komunikator albo serwis społecznościowy może być trudniejszy do klasyfikacji niż oryginalna próbka.

Osobnym ograniczeniem był model twarzowy. Analiza samej twarzy była przydatna, ale nie wystarczyła do pełnego rozwiązania problemu. Przyczyną jest to, że crop twarzy usuwa część kontekstu obrazu, a jednocześnie wymaga poprawnej detekcji twarzy. Dodatkowo mały zbiór adaptacyjny nie dawał wystarczająco dużo przykładów, aby model stabilnie nauczył się wszystkich wariantów nowych generatorów.

Najważniejszy wniosek metodologiczny jest następujący: model globalny stanowi mocny baseline dla fotografii i znanych danych, natomiast generalizacja na najnowsze generatory GPT / Gemini pozostaje ograniczona. W benchmarku OOD problem nie polegał wyłącznie na niewykrywaniu obrazów syntetycznych, ale również na generowaniu zbyt wielu fałszywych alarmów dla nowych prawdziwych portretów.

Równie istotny jest wniosek dotyczący etapu twarzowego. Sam fakt zastosowania osobnego modelu twarzowego nie gwarantuje poprawy na nowych danych. Pierwotne checkpointy twarzowe nie generalizowały dobrze na nowe obrazy GPT / Gemini, a dopiero mała adaptacja na nowych cropach pozwoliła uzyskać poprawę na zbiorze wewnętrznym. Nadal jednak ręczne testy pokazały trudne przypadki, w których nawet adaptowany model twarzowy klasyfikował syntetyczny portret jako **real**.

Oznacza to, że końcowy efekt pracy należy interpretować jako:

- działający system badawczy z pełnym pipeline’em,

- mocny baseline dla starszych i znanych danych,
- narzędzie pozwalające badać ograniczenia detekcji na nowszych generatorach,
- punkt wyjścia do dalszych prac nad lepszą generalizacją modeli twarzowych.

W kolejnych pracach najbardziej uzasadnione byłyby:

1. rozbudowanie zbioru OOD o większą liczbę obrazów z najnowszych generatorów,
2. przygotowanie większego i bardziej zrównoważonego zbioru adaptacyjnego dla twarzy,
3. sprawdzenie silniejszych metod detekcji twarzy i alternatywnych strategii croppingowania,
4. dalsza analiza modeli hybrydowych, które łączą sygnał globalny i twarzowy.

Można zatem stwierdzić, że projekt osiągnął wyraźny i mierzalny progres: posiada sprawdzony etap bazowy, rozszerzenie twarzowe, benchmark OOD oraz udokumentowaną analizę ograniczeń. Z punktu widzenia pracy końcowej jest to wartościowy rezultat, ponieważ pokazuje nie tylko implementację, ale też realistyczną ocenę granic skuteczności obecnych metod detekcji.

Bibliografia

- [1] Ramprasaath R. Selvaraju i in. „Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization”. W: *Proceedings of the IEEE International Conference on Computer Vision*. 2017.
- [2] Ian Goodfellow i in. „Generative Adversarial Nets”. W: *Advances in Neural Information Processing Systems 27*. 2014.
- [3] Jonathan Ho, Ajay Jain i Pieter Abbeel. „Denoising Diffusion Probabilistic Models”. W: *Advances in Neural Information Processing Systems 33*. 2020.
- [4] Kaiming He i in. „Deep Residual Learning for Image Recognition”. W: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2016.
- [5] Paul Viola i Michael Jones. „Rapid Object Detection using a Boosted Cascade of Simple Features”. W: *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*. 2001.
- [6] Zhuang Liu i in. „A ConvNet for the 2020s”. W: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (2022).

Spis rysunków

4.1. Przykład false positive na benchmarku OOD: prawdziwy portret sklasyfikowany jako fake	20
4.2. Przykład false negative na benchmarku OOD: obraz syntetyczny sklasyfikowany jako real	21
4.3. Przykładowa wizualizacja Grad-CAM wygenerowana dla modelu globalnego	23

Spis tabel

3.1. Uproszczony schemat działania systemu	9
3.2. Najważniejsze konfiguracje eksperymentów	12
4.1. Zakres wykonanych testów i porównań	15
4.2. Wpływ degradacji jakości obrazu na wyniki modelu globalnego	17
4.3. Macierz pomyłek modelu globalnego na benchmarku OOD	19
4.4. Porównanie modelu globalnego i twarzowego na podzbiorze OOD z wykrytą twarzą	19
4.5. Zbiorcze wyniki najważniejszych eksperymentów	20
5.1. Podsumowanie osiągniętych i nieosiągniętych celów	25

Spis listingów